哈尔滨工业大学深圳校区

毕业论文开题报告

题　　目	无需训练的高效多模态大模型幻觉缓解算法研究
姓　　名	徐景元
学　　号	220111030
学　　院	计算机科学与技术学院
专　　业	计算机类
指 导 教 师	陈斌
日　　期	2025 年 10 月 08 日

目 录

1 课题背景及研究的目的和意义 1
1.1 课题背景 1
1.2 研究的目的和意义 1
2 国内外研究现状及分析 3
2.1 国内外研究现状 3
2.2 国内外文献综述及简析 3
2.2.1 基于数据与模型微调的方法： 4
2.2.2 基于后处理与自我修正的方法 4
2.2.3 基于免训练的解码策略优化 5
3 主要研究内容及研究方案 7
3.1 研究内容 7
3.1.1. 视觉幻觉的内在机理分析： 7
3.1.2. 跨层注意力引导与局部信息扰动的耦合机理分析： 7
3.1.3. 对比度增强稀疏化解码（CESD）算法设计： 7
3.2 研究方案 8
3.2.1. 研究思路与技术路线： 8
3.2.2. 关键技术与研究方法 8
4 进度安排及预期目标 11
4.1 进度安排 11
4.2 预期目标 12
5 已具备和所需的条件和经费 14
5.1 实验室条件和经费保障 14
6 预计困难及解决方案 15

6.1 预计困难与技术难点 15
6.2 解决方案 15
[1]. 参考文献 16

1 课题背景及研究的目的和意义

1.1 课题背景

近年来，随着深度学习技术的飞速发展，多模态大模型（Multi-modal Large Language Models, MLLMs）已成为人工智能领域的研究热点，并在跨模态理解、内容生成、人机交互等多个方面展现出强大的能力。这类模型通过融合视觉和语言信息，能够完成诸如图像描述、视觉问答等复杂任务，在自动驾驶、医疗影像分析、智能机器人等领域显示出巨大的应用潜力。

然而，正如许多研究所指出的[1][2]，多模态大模型的一个核心挑战是其固有的“幻觉”（Hallucination）问题。这一现象被定义为模型在生成文本时，其内容与输入的视觉信息发生偏离，甚至完全矛盾[3]。例如，模型可能在图像中不存在某个物体的情况下“看到”并描述它，或者错误地描述物体的属性与关系。这种幻觉问题严重削弱了模型的可靠性和可信度，限制了其在关键任务中的实际部署。尤其在自动驾驶、医疗诊断等对准确性要求极高的场景中，由模型幻觉导致的错误判断可能引发严重的安全隐患和决策风险。

为了应对这一挑战，学术界和工业界已经探索了多种幻觉缓解策略。当前主流的方法大致可分为三类：后处理方法、指令微调（Instruction Fine-tuning）以及解码策略优化[2]。这些方法虽然在一定程度上缓解了幻觉问题，却普遍面临着“效率-性能”的权衡困境：后处理方法引入了额外的系统复杂度和计算开销；指令微调方法依赖昂贵的数据标注与训练资源；而解码策略优化则常常以牺牲推理速度为代价，难以满足实时应用的需求。

现有的幻觉缓解方法普遍存在着依赖额外训练、计算成本高或牺牲推理效率等问题。因此，探索一种无需额外训练、能够在解码阶段高效地缓解视觉幻觉，同时不显著增加计算负担的算法，对于提升多模态大模型的实用性和可靠性具有至关重要的理论价值和现实意义。本课题正是在此背景下展开，旨在研究一种无需训练的高效幻觉缓解算法，以推动多模态大模型在更广泛的实际场景中安全、可靠地应用。

1.2 研究的目的和意义

本课题旨在探索一种无需额外训练且高效的多模态大模型（MLLM）视觉幻觉缓解方案。当前，视觉幻觉问题，即模型生成内容与图像信息不符，已成为制约其在自动驾驶、医疗影像等关键领域应用的主要障碍。现有的无需训练的解码策略虽能缓解幻觉，却常因引入多轮解码或复杂校准机制而大幅牺牲推理效率[4]。

本研究旨在探索出一种在保证推理效率的前提下，引入视觉感知稀疏化思想的对比解码策略，用于缓解多模态大模型的幻觉现象。核心目的包括以下两个方面：

- **多模态大模型幻觉问题调研与分析：**调研当前流行 MLLMs 在视觉理解任务中的表现、当前主流的视觉幻觉缓解方法，从而根据调研结果，选定无需训练的高效多模态大模型幻觉缓解算法基线，并进行复现与改进
- **视觉感知稀疏化解码算法复现与优化：**受当前主流的幻觉缓解方法 VASparse[4]和 iTaD[5]的启发，引入视觉感知稀疏化思想和层间对比解码思路，基于 iTaD 算法的基本框架，探索在对比解码的中间业余层主动引入局部稀疏化对模型性能的影响，设计正确的优化方案，确保方法保证高推理效率的前提下，有效提升模型生成内容的真实性。

本课题在理论和应用上都有重要价值。从理论角度看，本研究将信息稀疏化从一种提升效率的方法，转变为增强模型对比信号的手段，为对比解码理论提供了新的思路。在应用方面，研究成果将是一个高效、即插即用的解码模块，能够方便地嵌入现有的多模态大模型中。该模块无需额外训练，也不会拖慢推理速度，但能有效提升模型的可靠性，从而降低高性能、高可信度多模态大模型在关键领域的应用门槛，助力下一代人工智能技术的发展

2 国内外研究现状及分析

2.1 国内外研究现状

近年来，多模态大模型（MLLMs）在跨模态理解与生成方面取得了显著进展。代表性模型如 LLaVA、Qwen-VL 等，能够在图文问答、图像描述和视觉推理任务中表现出较强的理解与生成能力。然而，模型在生成过程中仍容易出现“视觉幻觉”（Visual Hallucination）现象，即生成内容与输入图像不符。例如，模型可能虚构不存在的物体、错误描述物体属性，或误解物体之间的关系。这种问题在自动驾驶、医疗影像等高风险场景中尤其突出，已成为限制多模态模型应用的重要瓶颈 [6]。

下述表格总结了近年来对幻觉缓解方法的国内外研究现状。

研究方向	核心思路	优点	局限性
数据与模型微调	通过高质量数据集或 RLHF 改进模型训练，使模型从源头上学会更忠实的生成方式	提升模型固有能力，生成质量高	成本高，依赖大规模标注数据，迁移性差
后处理与自我修正	在推理后利用外部知识或强模型审校修正生成内容	灵活易用，可直接叠加到现有模型	推理延迟大，依赖外部模块
免训练的解码策略优化	在生成阶段通过调整注意力或概率分布，减少幻觉的发生	无需训练，计算开销低，通用性强	不同模型间泛化性有待验证

在此背景下，基于免训练的解码策略优化提出的对比解码方法受到越来越多的关注，受到两种主流对比解码 iTad 和 Vasparse 算法框架的启发，本研究提出一种新的对比解码策略，探索在对比解码的中间业余层主动引入局部稀疏化对模型性能的影响，构建出有效的优化方案，确保方案在保证推理效率的前提下，能有效缓解多模态大模型的幻觉问题。

2.2 国内外文献综述及简析

2.2.1 基于数据与模型微调的方法：

该方向从模型训练层面出发，通过优化训练数据、指令设计或学习目标，使模型在生成时更加忠实于视觉事实。其核心思想是通过端到端优化模型的视觉理解与文本生成一致性，从源头上提升模型的事实性与可控性。

- Liu 等人 [7] 指出，现有多模态数据集往往存在图文语义错配、描述模糊或噪声样本等问题，导致模型在微调时学习到错误的视觉语义映射。为此，他们提出在指令微调阶段引入语义一致性校验机制（Semantic Alignment Check），通过图像理解模型（如 CLIP）验证文本描述与视觉内容的相符性，从而显著提升模型在图文问答、图像描述等任务中的忠实性。
- opera 框架 [16] 通过引入“过度信任惩罚（Over-Trust Penalty）”与“回顾分配机制（Retrospection Allocation）”，鼓励模型在指令学习中更加关注视觉细节而非语言先验，从训练阶段抑制幻觉。
- 人类反馈强化学习（RLHF）[8] ：人类反馈强化学习（Reinforcement Learning from Human Feedback, RLHF）是语言模型事实性增强的重要方法，后续被扩展至多模态场景。研究者通过设计基于事实正确性的奖励函数，引导模型生成更贴近真实视觉内容的回答。
- Woodpecker [10] 将此方法拓展至视觉语言领域，结合视觉一致性奖励信号，使模型能在图像描述与视觉问答任务中自适应地校正幻觉输出。

该类方法的优势在于从源头上提升模型能力、改善视觉对齐，但其训练成本高、依赖大量标注数据与算力；且微调后的模型在迁移到新任务或新领域时常需重新训练，通用性与灵活性不足。

2.2.2 基于后处理与自我修正的方法

该方向不改变模型参数，而是在生成后对输出进行校验、修正或再生成，以提高事实一致性。其思路是利用外部知识或更强模型的推理能力，对原始生成进行二次过滤与优化。

- Shuster 等人 [9] 提出了检索增强生成（Retrieval-Augmented Generation, RAG）框架，通过引入外部知识库对生成内容进行事实验证，从而显著减少语言模型在对话中的幻觉。多模态版本的研究（如 Li 等人 [20]、[21]）则结合图像识别模型或物体检测结果，对生成描述进行逐项对齐与核查，确保图文一致。

- Woodpecker [10] 则代表了基于模型审校的典型方案，其利用更强的多模态模型（如 GPT-4V）对较弱模型生成的描述进行**“重写式校正（Rewrite-based Correction）”**，从而在不重训练的情况下快速提升生成准确性。
- 自我反思（Self-Reflection）机制被广泛用于语言模型的事实校正。Zhang 等人 [19] 提出“自我纠错解码（Self-Correcting Decoding, SCD）”框架，让模型在生成后自评事实一致性并通过“生成反馈（Generative Feedback）”进行多轮修正，显著降低了视觉描述任务中的错误率。

该类方法具有灵活、可直接应用于已有模型等优点，但其主要问题在于计算开销和响应延迟较高；同时，依赖外部模型或知识库的策略在跨领域任务中泛化性有限。

2.2.3 基于免训练的解码策略优化

免训练策略从推理阶段（Decoding）入手，通过调整生成算法来抑制幻觉。这类方法近年来发展迅速，因其无需额外数据、无需修改模型参数、可即插即用而受到广泛关注。

- 层间对比解码（Layer-wise Contrastive Decoding, LCD）：该方法基于一个关键观察：模型在不同层次的生成分布中，低层更多依赖输入（包括视觉特征），高层则更倾向语言流畅性与上下文先验。
  - Leng 等人 [11] 与 Chuang 等人 [12] 提出在解码阶段对不同层的输出概率分布进行对比，通过惩罚跨层不一致的生成结果，从而抑制幻觉内容。
  - Li 等人 [15] 的“对比解码（Contrastive Decoding, CD）”框架进一步将该思想推广到开放式文本生成中，被广泛应用于视觉-语言模型的视觉事实约束中。
  - Xu 等人 [5] 的 iTaD 方法在此基础上引入图像注意力向量（Image Attention Vector, iTaV），通过动态选择与最终层视觉理解差异最大的中间层进行对比，实现了在精度与效率之间的平衡。
  - Zhuang 等人 [4] 提出的 VASparse 则探索了基于视觉不可知原则（Visual-Agnostic Principle）的稀疏化策略，通过减少视觉 Token 数量来加速推理。然而，该策略虽提升了效率，却因稀疏化导致视觉信息损失，从而增加了幻觉风险。

免训练解码策略具有计算轻量、部署便捷等优势，是当前多模态幻觉研究中最具实践潜力的方向之一。然而，由于不同模型的结构差异（如视觉编码器类型、Token 融合方式）较大，这类方法的通用性与鲁棒性仍有待进一步研究。

3 主要研究内容及研究方案

3.1 研究内容

本研究的核心目标是设计并实现一种基于局部稀疏化的对比度增强解码策略（Contrast-Enhanced Sparsified Decoding, CESD），以更精巧、更主动的方式缓解大型视觉语言模型（LVLM）的视觉幻觉。该策略旨在通过在解码过程中的特定中间层注入可控的“信息扰动”，人为地放大模型最终层（专家）与中间层（业余）在视觉理解上的差异，从而实现更高效、更鲁棒的幻觉抑制。主要研究内容包括以下几个方面：

3.1.1. 视觉幻觉的内在机理分析：

- 受到 VASparse 研究的启发，研究模型注意力分布的稀疏性特征，以及不合理的 token 稀疏化（尤其是对视觉关键信息的忽略）如何加剧幻觉 。
- 受到 iTaD 研究的启发，量化分析模型在生成过程中，输出 token 对输入图像 token 的注意力权重变化规律，验证幻觉内容与对图像 token 注意力下降之间的强相关性 。

3.1.2. 跨层注意力引导与局部信息扰动的耦合机理分析：

- **跨层视觉理解的动态追踪：** 沿用 iTaD 的思想，通过计算并比较各解码层的图像 Token 注意力向量（iTaV），量化模型从浅层到深层对图像理解的“进化”过程。分析并确定最能代表“业余”视觉理解水平、与最终层差异最大的关键中间层。
- **视觉不可知稀疏化的影响：** 借鉴 VASparse 的观察，深入研究在模型的中间层输入上施加视觉不可知(vision-agnostic)的 Token 稀疏化(如 Vanilla Top-K)，如何影响该层的特征表示和后续的输出分布。重点分析这种局部信息损失是否能有效模拟并放大模型依赖语言先验而非视觉输入的“幻觉倾向”。

3.1.3. 对比度增强稀疏化解码（CESD）算法设计：

- **动态对比层选择：** 首先，模型基于完整的输入 token 序列进行一次完整的前向传播，计算出所有解码层的 iTaV。采用 iTaD 中的 JSD 距离度量方法，动

态选择出与最终层（第 N 层）iTaV 距离最大的中间层（第 M 层）作为对比目标。

- **构建稀疏化的“业余”Logits：** 这是本方案的核心创新。我们并不直接使用第 M 层原始的输出。而是在第 M 层的输入隐状态上，应用视觉不可知的稀疏化策略（如移除注意力得分最低的一部分 token）。随后，仅让这个“信息受损”的隐状态通过第 M 层，计算出一个被干扰的、信息不全的“业余”logits 分布。
- **“专家-业余”对比解码：** 最后，将第 N 层基于完整信息计算出的“专家”logits，与第 M 层经过局部稀疏化处理后生成的“业余”logits 进行对比解码。通过惩罚“业余”logits 中概率较高而“专家”logits 中概率较低的 token，有效抑制那些在信息不全时更容易产生的幻觉内容。

3.2 研究方案

本研究的技术路线旨在将动态层选择与局部稀疏化注入相结合，以增强最终的对比解码效果。为有序推进上述研究，本研究将采用以下技术方案：

3.2.1. 研究思路与技术路线：

本研究的技术路线旨在将动态层选择与局部稀疏化注入相结合，以增强最终的对比解码效果。技术路线描述如下：首先，模型进行一次完整计算，得到最终层的输出 logits 和所有层的 iTaV。然后，根据 iTaV 的距离选择出最佳的对比层 M。接着，在 M 层的输入上执行局部稀疏化，并计算出一个“业余”logits。最后，利用最终层的“专家”logits 和 M 层产生的“业余”logits 进行对比解码，生成最终的 token。这个过程在每个解码步骤中重复进行。

3.2.2．关键技术与研究方法

- **跨层注意力分析与动态层选择**

这是实现自适应对比解码的基础。首先，在解码的第 t 步，对于第 n 层的解码器，我们构建其图像 Token 注意力向量（iTaV），它代表了当前输出对所有输入图像 Token 的注意力分布。其计算方式如下：

$$\mathrm{iTaV}_t^n = \mathrm{softmax}\left(\left[\hat{v}_{t,I_s}^{n}, \ldots, \hat{v}_{t,I_e}^{n}\right]\right)$$

其中 $\hat{v}^{n}_{t,j}$ 的计算方式为：

$$\hat{v}^{n}_{t,j} = \max_{h} w^{n}_{t,h,j}$$

在这里，$w^{n}_{t,h,j}$是第 n 层第 h 个注意力头中，当前查询对第 j 个 key 的注意力权重，$[I_s, I_e]$ 是图像 token 的索引范围。然后，我们采用 **Jensen-Shannon Divergence (JSD)** 来度量最终层 N 与某个中间候选层 M 的 iTaV 之间的距离，并选择距离最大的层作为“业余”层进行对比。

JSD 是一个对称且平滑的度量，非常适合衡量两个概率分布的差异性。这个动态选择机制使得算法能够根据当前上下文，自适应地找到最能体现“信息差”的对比层。

- **局部信息扰动（局部稀疏化）技术**

为了主动增强对比度，我们在选定的中间层 M* 的输入隐状态 h^{M*-1} 上施加视觉不可知的稀疏化。主要采用 **Vanilla Top-K** 策略，保留注意力分数最高的 k 个 token，屏蔽其余 token。

$$h^{M*-1}_{\text{sparse}} = \text{Top-K}\left(h^{M*-1}, k\right)$$

被稀疏化处理后的 h^{M*-1}_{sparse} 再通过第 $M*$ 层计算，得到“业余”logits。这种方法模拟了信息不完整的情况，能有效暴露模型仅依赖语言先验的倾向，从而为后续的对比解码创造更有利的条件。

- **实验验证法：**
  - **基座模型：**选用 **LLaVA-1.6、QwenVL2.5** 等代表性 MLLM，以验证 CESD 算法的通用性和即插即用特性。
  - **评估基准：**
    - **对象幻觉：** 使用 **MSCOCO** 数据集和 **CHAIR** 指标 (CI , CS)。
    - **存在性判断幻觉：** 使用 **POPE** 基准和 **F1-score**。
    - **综合评估：** 辅以 **MME** 等基准进行更全面的评估。

- **对比基线：** 包括标准解码（Greedy, Beam Search）以及先进的幻觉缓解方法（VASparse, iTaD, OPERA, VCD 等）。

4 进度安排及预期目标

4.1 进度安排

本课题的研究时间为 2025 年 8 月开始至 2026 年 6 月份进行答辩，根据之前的项目经验，结合自身学习，科研攻关能力，针对课题研究计划，制定出下面的研究进度:

第 1-5 周 (2025.10 - 2025.11 上旬): 文献调研与方案细化

- 深入研读 VASparse、iTaD 等核心文献及相关解码策略研究。
- 完成并提交开题报告。
- 最终确定 CESD 算法的具体技术细节和实验设计。

第 6-8 周 (2025.11 中旬 - 2025.12 上旬): 环境搭建与初步实现

- 搭建 PyTorch 和 HuggingFace 实验环境，配置所需模型和数据集。
- 完成数据预处理脚本，并实现 CESD 算法的基础框架。

第 9-12 周 (2025.12 中旬 - 2026.01 中旬): 核心算法开发与调试

- 重点实现动态对比层选择和局部稀疏化注入模块。
- 进行单元测试和集成调试，确保算法流程正确无误。
- 在小规模数据集上进行初步实验，验证算法可行性。

第 13-16 周 (2026.01 下旬 - 2026.03 上旬): 全面实验与结果分析

- 在所有选定的基座模型和评估基准上进行大规模实验。
- 系统收集、整理并分析实验数据，与各项基线方法进行对比。
- 完成参数敏感性分析和消融实验。

第 17-19 周 (2026.03 中旬 - 2026.04 中旬): 论文初稿撰写

- 根据实验结果，完成毕业设计论文的核心章节（引言、相关工作、方法、实验等）的撰写。

第 20-22 周 (2026.04 下旬 - 2026.05 中旬): 论文修改与完善

- 根据指导老师的意见修改和润色论文。
- 检查并修正论文格式、图表和参考文献。
- 完成论文终稿。

第 23 周以后 (2026.05 下旬 - 2026.06): 答辩准备与最终答辩

- 准备答辩 PPT。
- 进行答辩预演。
- 完成毕业设计答辩。

4.2 预期目标

本课题旨在探索一种**无需额外训练、能够在解码阶段高效缓解视觉幻觉且计算开销较低的算法**——局部稀疏化的对比度增强解码策略（Contrastive Enhancement with Sparse Decoding, CESD）。研究将围绕以下四个目标展开：

- **基线方法性能复现**：选取两种及以上主流的大型视觉语言模型（如 LLaVA-1.6）作为实验基座，在统一的环境下复现多种现有解码策略，包括标准解码方法及代表性改进方法（如 iTaD、VASparse 等）。在 CHAIR 和 POPE 等公开基准上测试各方法的幻觉水平与解码效率，为后续 CESD 算法的性能比较提供可靠基线。
- **CESD 算法设计与验证**：完整实现 CESD 算法，并将其以“即插即用”模块的形式集成到基座模型中。在相同评测标准下开展综合实验，验证算法的主要创新点。预期 CESD 能在不显著增加计算成本的前提下，进一步降低模型幻觉率（如更低的 CHAIR 得分）并提升输出准确性（如更高的 POPE F1 值），达到或超过现有先进方法的性能。
- **算法鲁棒性与机理分析**通过消融实验分析 CESD 各组成模块（如动态层选择与局部稀疏化）的实际作用，明确其对整体性能的影响。同时，开展参数敏感性实验，考察关键超参数（如对比强度 λ、稀疏化比例 k）对模型表现的影响规律，为算法调优与应用提供理论支撑和经验依据。

- **成果总结与论文撰写**：综合实验结果与机理分析，系统展示 CESD 算法的技术创新与性能优势，形成结构完整、内容翔实的毕业设计论文。预期结果表明，本算法在解码忠实性、一致性及计算效率方面均能较基线方法取得明显提升，验证其在增强视觉语言模型可靠性与实用性方面的研究价值。

5 已具备和所需的条件和经费

5.1 实验室条件和经费保障

实验室目前已具备常规的科研办公条件。在经费保障方面，本课题拟通过科研经费支持多模态大模型 API 的调用费用，用于毕设的相关研究。同时，实验室已已具备一定的 GPU 计算资源，可支撑中小规模模型（如 7B，8B 参数规模）的部署和推理，从而在保证实验可行性的同时，降低经费支出压力。

6 预计困难及解决方案

6.1 预计困难与技术难点

本课题的预计困难与技术难点有：

- 超参数的权衡与调优： 算法涉及多个相互影响的超参数（如稀疏化比例、对比强度等），如何在增强对比效果和避免关键信息损失之间找到最佳平衡点，是核心的技术挑战。
- 算法实现的复杂度与计算开销： 所提出的解码策略需要在每个生成步骤中进行多次前向计算，这会带来额外的计算开销和时间延迟，可能影响算法的实用性。
- 模型间的泛化能力： 算法的效果可能依赖于特定的大模型架构，如何保证其在不同结构（如 MLP 投影器 vs. Q-Former）的视觉语言模型上均能表现出稳定且优异的性能，存在不确定性。

6.2 解决方案

为了提高课题进展速度和效率，针对上述的困难拟定解决方案如下：

- 设计系统的消融实验与参数敏感性分析： 建立独立的验证集，采用控制变量法，系统性地分析各超参数对算法性能的影响，并通过网格搜索等方法寻找最优参数组合。
- 优化代码实现并进行性能权衡分析： 通过缓存中间计算结果等方式对代码进行深度优化，以降低时间开销。同时，将解码效率（TPS）作为关键指标之一，量化分析算法性能提升与效率损失之间的权衡关系。
- 在多种模型与任务上进行交叉验证： 选取架构差异化的多种主流模型进行实验，并在图像描述、视觉问答等不同任务上进行测试，以全面评估算法的泛化能力与适用边界。

[1]. 参考文献

[1]. Yin S, Fu C, Zhao S, et al. A survey on multimodal large language models[J]. National Science Review, 2024, 11(12): nwae403.

[2]. Liu H, Xue W, Chen Y, et al. A survey on hallucination in large vision-language models[J]. arXiv preprint arXiv:2402.00253, 2024.

[3]. Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language generation[J]. ACM computing surveys, 2023, 55(12): 1-38.

[4]. Zhuang X, Zhu Z, Xie Y, et al. VASparse: Towards Efficient Visual HallucinationMitigation via Visual-Aware Token Sparsification[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 4189-4199.

[5]. Xu X, Chen H, Lyu M, et al. Mitigating Hallucinations in Multi-modal Large LanguageModels via Image Token Attention-Guided Decoding[C]//Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2025: 1571-1590.

[6]. Li Y, Du Y, Zhou K, et al. Evaluating object hallucination in large vision-language models[J]. arXiv preprint arXiv:2305.10355, 2023.

[7]. Liu F, Lin K, Li L, et al. Mitigating hallucination in large multi-modal models via robust instruction tuning[J]. arXiv preprint arXiv:2306.14565, 2023

[8]. Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in Neural Information Processing Systems, 2022, 35: 27730-27744.

[9]. Shuster K, Poff S, Chen M, et al. Retrieval augmentation reduces hallucination in conversation[C]//Findings of the Association for Computational Linguistics: EMNLP 2021. 2021: 3784-3803.

[10]. Yin S, Fu C, Zhao S, et al. Woodpecker: Hallucination correction for multimodal large language models[J]. Science China Information Sciences, 2024, 67(12): 220105.

[11]. Leng S, Zhang H, Chen G, et al. Mitigating object hallucinations in large vision-language models through visual contrastive decoding[C]//Proceedings of

the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 13872-13882.

[12]. Chuang Y S, Xie Y, Luo H, et al. Dola: Decoding by contrasting layers improves factuality in large language models[J]. arXiv preprint arXiv:2309.03883, 2023.

[13]. Li X L, Holtzman A, Fried D, et al. Contrastive decoding: Open-ended text generation as optimization[J]. arXiv preprint arXiv:2210.15097, 2022.

[14]. Chen Z, Chen Z, Zhao Z, et al. Halc: Object hallucination reduction via adaptive focal-contrast decoding[J]. arXiv preprint arXiv:2403.00425, 2024.

[15]. Li X L, Holtzman A, Fried D, et al. Contrastive decoding: Open-ended text generation as optimization[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 12286-12312.

[16]. Huang Q, Dong X, Zhang P, et al. Opera: Alleviating hallucination in multi-modal large language models via over-trust penalty and retrospection-allocation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 13418-13427.

[17]. Chen L, Zhao H, Liu T, et al. An image is worth 1/2 tokens after layer 2: Plug-and-play inference acceleration for large vision-language models[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 19-35.（FastV）

[18]. Yang S, Chen Y, Tian Z, et al. Visionzip: Longer is better but not necessary in vision language models[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 19792-19802.(visionzip)

[19]. Zhang C, Wan Z, Kan Z, et al. Self-correcting decoding with generative feedback for mitigating hallucinations in large vision-language models[J]. arXiv preprint arXiv:2502.06130, 2025.

[20]. Li Y, Du Y, Zhou K, et al. Evaluating object hallucination in large vision-language models[J]. arXiv preprint arXiv:2305.10355, 2023.

[21]. Li B, Ge Y, Ge Y, et al. Seed-bench: Benchmarking multimodal large language models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 13299-13308.

[22]. Rohrbach A, Hendricks L A, Burns K, et al. Object hallucination in image captioning[J]. arXiv preprint arXiv:1809.02156, 2018.

[23]. Fu C, Zhang Y F, Yin S, et al. Mme-survey: A comprehensive survey on evaluation of multimodal llms[J]. arXiv preprint arXiv:2411.15296, 2024.